

MAPEAMENTO DE PROCESSOS

COMPONENTE CURRICULAR:	PROJETO APLICADO 2
NOME COMPLETO DO ALUNO:	GUILHERME CUNHA OLIVEIRA, GABRIEL LUCCA SIMIONATO
RA:	10754621, 10751300

Atenção: Toda atividade deverá ser feita com fonte Arial, tamanho 11, espaço de 1,5 entre as linhas e alinhamento justificado entre as margens.

PROPOSTA DE ANÁLISE DA DENGUE

1. Apresentação do mapeamento

Este mapeamento apresenta a proposta do projeto: objetivos, fontes selecionadas, métodos analíticos candidatos, ferramentas, justificativas, limitações e ordem prevista das atividades. Sua finalidade é roteirizar e organizar o caminho entre os dados brutos e os resultados esperados, antes das análises.

A descrição seguirá o conceito de processo apresentado em Aquisição e Preparação de Dados: atividades relacionadas que utilizam entradas, recursos e procedimentos para gerar saídas. O fluxo apresentará dependências e possibilidades de revisão, sem antecipar resultados.

Função dos arquivos

O mapeamento apresentará o que se pretende realizar. Os quatro relatórios de etapa apresentarão os resultados e suas interpretações; o diário acompanhará o andamento e as sínteses durante o trabalho; o modelo de análise detalhará o diagrama conceitual. Notebooks e scripts concentrarão análises executáveis, códigos e procedimentos.

Escopo

A proposta manterá quatro fontes: SINAN/Dengue, CNES/Hospitais e Leitos, IBGE/Censo 2022 e Informes Semanais de Arboviroses de 2025.

2. Objetivos, problema analítico

Objetivo geral

Identificar perfis associados à classificação de dengue com sinais de alarme ou dengue grave, utilizando atributos dos casos e contexto municipal, e complementar sua interpretação com informações extraídas dos textos dos informes.

Objetivos específicos

O projeto vai usar Regressão Logística, verificar a contribuição do CNES e do IBGE em relação ao SINAN isolado e descrever localidades e tendências mencionados nos documentos.

Cada registro elegível será considerado um caso. A variável alvo será baseada no campo CLASSI_FIN: código 10 será classificado como 0 (dengue) e os códigos 11 e 12 como 1 (dengue com sinais de alarme ou dengue grave). Outras classificações e valores ausentes serão excluídos da análise.

3. Fontes selecionadas e papel no projeto

SINAN/Dengue

Registros de 2025 e dicionário: fornecerão o alvo, perfil demográfico, comorbidades e atributos clínicos candidatos. A seleção considerará preenchimento, significado e disponibilidade temporal.

CNES/Hospitais e Leitos

Leitos de 2025 e dicionário: fornecerão contexto de capacidade assistencial por município e competência. Leitos cadastrados não serão interpretados como leitos livres ou como hospital.

IBGE/Censo 2022


Agregados municipais básico e domicílios 1, 2 e 3: fornecerão população e indicadores candidatos de água, esgotamento e lixo. As medidas conservarão a referência de 2022; o contexto municipal não descreverá o domicílio individual.

Informes Semanais

A coleção selecionada de 2025 formará o corpus, isto é, o conjunto de

textos. A análise priorizará as seções de dengue e respeitará o período de cada documento; acumulados de informes sucessivos não serão somados.

Visão conceitual da proposta



Fonte: elaboração para a proposta. O texto complementar à interpretação, não será repetido como atributo de cada caso.

4. Abordagem de processos e requisitos

O projeto seguirá as etapas do CRISP-DM: entendimento do problema e dos dados, preparação, modelagem, avaliação e apresentação dos resultados.

Os processos funcionais incluem preparar e integrar os dados, analisar os textos e usar o modelo de classificação. Já os requisitos de qualidade envolvem preservar os dados originais, garantir a reprodução da análise e manter consistência durante o processo.

5. Métodos analíticos e ferramentas previstas

Estatística descritiva e visualização

Serão utilizadas frequências, proporções, medidas de tendência central e dispersão, acompanhadas de gráficos, com pandas, NumPy e Matplotlib. A escolha vai nos permitir conhecer distribuições, ausências e perfis antes da modelagem. Limite: descrições e associações não demonstrarão causa, mais casos em um grupo não significarão maior risco.

Regressão Logística

Combinará os atributos em uma expressão linear transformada pela função logística para classificação binária. Será candidata por sua correspondência com o alvo 0/1 e pela possibilidade de examinar a contribuição dos atributos. A implementação prevista utilizará scikit-learn. Limitações: a forma linear pode não representar relações complexas; a interpretação depende da codificação e da correlação entre atributos. Coeficientes não serão efeitos causais.

Extração de informação textual

Serão combinadas extração de texto por página, segmentação das seções de dengue, regras de termos/localidades e frequências. Como complemento, TF-IDF destacará termos relativamente distintivos entre documentos. A escolha permitirá uma análise rastreável sem exigir exemplos textuais previamente rotulados. Limitações: repetição entre informes, ambiguidade e perda de contexto. Ausência de menção não representará ausência de casos.

Linguagem, bibliotecas e ambiente

Python será a linguagem principal. A implementação utilizará notebooks para exploração e scripts para execução reproduzível.

Recurso	Finalidade e justificativa	Limite ou cuidado
pandas e NumPy	Ler CSV, organizar tabelas, integrar fontes e calcular indicadores. São o núcleo de manipulação usado no curso.	O consumo de memória orientará a leitura e o volume trabalhado.
Matplotlib	Visualizar distribuições, comparações e resultados; gráficos complementarão as medidas descritivas.	As escalas e os valores usados como base nos cálculos deverão ser informados claramente.
scikit-learn	Preparar atributos, comparar classificadores, calcular métricas e representar.	Preparação aprendida apenas no treino; mesmas regras na avaliação.


Recurso	Finalidade e justificativa	Limite ou cuidado
pdfplumber	Extraí texto por página, recurso complementar escolhido para manter a origem das menções.	PDFs digitalizados ou layouts complexos podem exigir revisão da extração.
openpyxl	Ler o dicionário do IBGE em XLSX, complemento para consultar metadados sem editar a fonte [TC4].	Planilhas e nomes de colunas deverão ser conferidos.
Biblioteca padrão do Python	Trabalhar com caminhos (pathlib), regras textuais (re) e integridade (hashlib), sem dependências adicionais.	Regras textuais precisam de revisão de contexto.
Git, GitHub e Git LFS	Manter organização, colaboração e arquivos brutos no repositório definido pelo grupo.	Um ponteiro LFS não substitui o arquivo real para executar a leitura.

As versões serão definidas depois de conferir a compatibilidade. Vamos começar com as fontes definidas.

6. Sequência dos processos

P01 a P08 representam etapas internas do projeto, e não entregas dos “Aplicando Conhecimento”. Depois de entender os dados de entrada, as análises dos dados tabulares e dos textos poderão ser desenvolvidas em paralelo.

Fluxograma da execução prevista



7. Padrão de qualidade e método de avaliação

Os critérios definirão a qualidade esperada. Registros de verificações e resultados permanecerão nos relatórios, no diário e nos arquivos de análise.

Dimensão	Padrão e forma de avaliação previstos
Integridade e origem	Preservar os originais; conferir identidade dos arquivos, fonte, período e leitura do dado real.
Coerência e completude	Conferir códigos, unidades, datas e ausências pelos dicionários. Diferenciar nulo, ignorado, não aplicável e zero.
Integração	Exigir unicidade na chave contextual e preservar casos na junção. Mensurar correspondências e não correspondências.
Validade temporal	Verificar momento dos atributos e competência das fontes. Excluir do conjunto preditor informações que revelem o alvo.
Qualidade textual	Vincular as menções utilizadas a documento, página e trecho. Revisar localidade, doença, negação e período.
Reprodução e viabilidade	Repetir execução com as mesmas entradas, configurações e sementes. Avaliar tempo e memória no ambiente disponível.