

PLANO DE LIMPEZA DAS BASES

Projeto Aplicado II - Dengue

Roteiro técnico para tratamento das fontes SINAN, CNES, IBGE e Informes
Semanais de Arboviroses.

Finalidade: orientar a limpeza das bases sem alterar os arquivos brutos, mantendo rastreabilidade, reprodutibilidade e separação entre entrada, processamento, validação e saída.

Versão de trabalho - etapa de tratamento dos dados

1. Princípios da etapa de limpeza

A partir desta etapa, os arquivos localizados em db/bases_brutas/ devem permanecer preservados. Nenhuma rotina de limpeza deverá sobrescrever as fontes originais. As transformações produzirão novas saídas em uma camada separada, permitindo repetir o processo e comparar o dado tratado com a origem.

```
db/
  ■■■ bases_brutas/
  ■ ■■■ sinan/
  ■ ■■■ cnes/
  ■ ■■■ ibge/
  ■ ■■■ informes/
  ■■■ bases_tratadas/
  ■■■ sinan/
  ■■■ cnes/
  ■■■ ibge/
  ■■■ informes/
```

Os notebooks deverão ser organizados por fonte. A proposta inicial é:

```
notebooks/
  ■■■ 01_limpeza_sinan.ipynb
  ■■■ 02_limpeza_cnes.ipynb
  ■■■ 03_limpeza_ibge.ipynb
  ■■■ 04_limpeza_informes.ipynb
```

Regra central: o notebook mostra o processo e suas verificações; o relatório acadêmico posteriormente apresenta os resultados consolidados. Os dados brutos permanecem imutáveis.

2. Ordem recomendada de processamento

Ordem	Fonte	Motivo principal
1	SINAN	Base principal do projeto e origem do alvo de classificação.
2	CNES	Contexto de infraestrutura de saúde por município.
3	IBGE	Contexto populacional e domiciliar por município.
4	Informes	Componente textual, com extração e normalização separadas.

O SINAN deve ser tratado primeiro porque determina a população elegível, as variáveis clínicas e demográficas e a chave territorial que depois será utilizada para integrar CNES e IBGE.

3. Limpeza do SINAN

Arquivo de entrada previsto: db/bases_brutas/sinan/dados/DENGBR25.csv. A saída poderá ser gravada como db/bases_tratadas/sinan/sinan_dengue_2025_tratado.csv.

3.1 Diagnóstico inicial

- Identificar encoding, separador, número de linhas e colunas e tipos inicialmente inferidos.
- Verificar os códigos efetivamente presentes em CLASSI_FIN e nas variáveis clínicas.

- Calcular quantidade e percentual de valores ausentes por coluna.
- Verificar linhas totalmente duplicadas e possíveis duplicidades de notificação.
- Conferir datas de notificação, início de sintomas e demais campos temporais relevantes.

3.2 Colunas administrativas candidatas à remoção

TP_NOT
ID_AGRAVO
ID_REGIONA
ID_UNIDADE
ID_RG_RESI
ID_PAIS
DT_INVEST
NDUPLIC_N
DT_DIGITA
CS_FLXRET
FLXRECEBI
MIGRADO_W
TP_SISTEMA

A remoção será confirmada com o dicionário de dados e com o objetivo analítico. A regra é excluir campos que não contribuam para a classificação proposta ou que funcionem apenas como controle operacional da notificação.

3.3 Informações candidatas à permanência

Grupo	Campos candidatos
Demográficas	NU_IDADE_N, CS_SEXO, CS_GESTANT, CS_RACA, CS_ESCOL_N, ID_OCUPA_N
Localização	SG_UF, ID_MN_RESI
Sintomas	FEBRE, MIALGIA, CEFALeia, EXANTEMA, VOMITO, NAUSEA, DOR_COSTAS, CONJUNTVIT, ARTRITE, AF
Comorbidades	DIABETES, HEMATOLOG, HEPATOPAT, RENAL, HIPERTENSA, ACIDO_PEPT, AUTO_IMUNE
Datas iniciais	DT_NOTIFIC, DT_SIN_PRI, SEM_NOT, SEM_PRI, NU_ANO

3.4 Prevenção de leakage

Campos que revelam sinais de alarme, gravidade, evolução ou informações posteriores ao momento pretendido de classificação não devem entrar como variáveis preditoras. Exemplos:

ALRM_HIPOT, ALRM_PLAQ, ALRM_VOM, ALRM_SANG, ALRM_HEMAT,
ALRM_ABDOM, ALRM_LETAR, ALRM_HEPAT, ALRM_LIQ, DT_ALRM

GRAV_PULSO, GRAV_CONV, GRAV_ENCH, GRAV_INSUF, GRAV_TAQUI,
GRAV_EXTRE, GRAV_HIPOT, GRAV_HEMAT, GRAV_MELEN, GRAV_METRO,
GRAV_SANG, GRAV_AST, GRAV_MIOC, GRAV_CONSC, GRAV_ORGAO, DT_GRAV

EVOLUCAO, DT_OBITO, DT_ENCERRA

Esses campos podem permanecer em uma cópia de auditoria ou ser usados para análise descritiva, mas não devem alimentar a Regressão Logística se estiverem disponíveis apenas após o agravamento ou desfecho.

3.5 Construção do alvo

CLASSI_FIN	Alvo proposto
10	0 - Dengue
11	1 - Dengue com sinais de alarme
12	1 - Dengue grave

Casos descartados, classificações incompatíveis com a população-alvo ou registros sem classificação válida deverão ser excluídos do conjunto de treinamento, mas suas quantidades precisam ser registradas antes da exclusão.

```
Total original: X
Dengue comum: X
Dengue com sinais de alarme: X
Dengue grave: X
Descartados/outros: X
Base final elegível: X
```

3.6 Valores ausentes e códigos de ignorado

Não será utilizada uma remoção indiscriminada de registros com `dropna()`. Primeiro será calculada a ausência por variável; em seguida, cada campo será tratado conforme seu significado no dicionário. Códigos de "ignorado" ou "não informado" não devem ser confundidos automaticamente com ausência física no arquivo.

```
df.isna().sum()
(df.isna().mean() * 100)
```

Para sintomas e comorbidades, a codificação deverá ser validada no dicionário antes de recodificar. Um valor diferente de "Sim" não pode ser transformado automaticamente em "Não" sem confirmação.

3.7 Datas

Datas relevantes deverão ser convertidas para tipo temporal. Uma variável candidata é o intervalo entre início dos sintomas e notificação:

```
dias_ate_notificacao = DT_NOTIFIC - DT_SIN_PRI
```

Valores negativos, datas impossíveis e datas fora do período esperado deverão ser investigados antes de qualquer correção ou exclusão.

3.8 Duplicidades

Primeiro serão contabilizadas linhas totalmente duplicadas. Depois, serão investigadas combinações de campos que possam indicar mais de uma notificação para o mesmo caso. Não será aplicado `drop_duplicates()` de forma automática sem compreender a origem da repetição.

4. Limpeza do CNES

A base CNES terá como objetivo gerar indicadores municipais de infraestrutura de saúde. A saída esperada deverá possuir uma granularidade compatível com a integração posterior ao SINAN.

Entrada: Leitos_2025.csv
Saída: cnes_municipio_2025_tratado.csv

Processo previsto:

```
leitura
↓
validação de tipos
↓
normalização do código municipal
↓
validação das categorias de leito
↓
tratamento de ausências
↓
agregação por município e período
```

Estrutura desejada:

```
cod_municipio
competencia
leitos
leitos_sus
leitos_uti
```

A quantidade absoluta de leitos deverá ser interpretada com cautela. Quando combinada à população municipal do IBGE, poderá gerar indicadores relativos como leitos por 100 mil habitantes, tornando municípios de tamanhos distintos mais comparáveis.

5. Limpeza do IBGE

O IBGE será mantido no projeto como fonte de contexto populacional e domiciliar. Os quatro arquivos tabulares deverão ser tratados com apoio do dicionário oficial, sem selecionar códigos de variáveis apenas pelo nome do arquivo.

Agregados_por_municipios_basico_BR.csv
Agregados_por_municipios_caracteristicas_domicilio1_BR.csv
Agregados_por_municipios_caracteristicas_domicilio2_BR.csv
Agregados_por_municipios_caracteristicas_domicilio3_BR.csv

Objetivo da preparação:

```
cod_municipio
populacao
indicadores de abastecimento de agua
indicadores de esgotamento sanitario
indicadores de coleta de lixo
outros indicadores domiciliares aprovados
```

Após a seleção correta dos numeradores e denominadores, poderão ser criadas proporções, por exemplo:

```
pct_agua  
pct_esgoto  
pct_coleta_lixo
```

A saída deverá possuir uma única linha por município antes da integração com o SINAN. A compatibilidade entre o código municipal do IBGE e ID_MN_RESI do SINAN será validada explicitamente.

6. Limpeza dos Informes Semanais

Os 17 informes em PDF constituem uma trilha textual separada das bases tabulares. O objetivo da limpeza não será transformar os PDFs diretamente em variáveis clínicas, mas criar um corpus textual rastreável para análise posterior.

```
PDF  
↓  
extração de texto  
↓  
remoção de cabeçalhos e rodapés  
↓  
identificação da página  
↓  
seleção da seção de dengue  
↓  
normalização de espaços e quebras  
↓  
texto limpo
```

Estrutura recomendada de saída:

```
informe  
pagina  
texto_original  
texto_limpo
```

A rastreabilidade é obrigatória: qualquer resultado textual deverá permitir voltar ao informe e à página de origem. Como os informes apresentam valores acumulados em diferentes semanas epidemiológicas, eles não devem ser somados entre si como se fossem observações independentes.

7. Estrutura padrão dos notebooks

Os quatro notebooks deverão seguir uma organização semelhante para facilitar manutenção, revisão acadêmica e reprodução.

Seção	Conteúdo
1. Objetivo	Finalidade da limpeza daquela fonte.
2. Bibliotecas	Pacotes efetivamente utilizados.
3. Caminhos	Entradas e diretórios de saída.
4. Carregamento	Leitura do arquivo sem alterar o bruto.
5. Diagnóstico inicial	Dimensões, tipos, nulos, códigos, duplicidades e problemas identificados.
6. Regras de limpeza	Regras aprovadas antes da transformação.
7. Aplicação	Execução das transformações.
8. Validação	Verificações de consistência após o tratamento.
9. Exportação	Gravação na camada de bases tratadas.
10. Resumo	Contagens antes/depois e principais transformações realizadas.

```
# =====  
# 1. OBJETIVO  
# =====
```

A padronização visual dos notebooks não é apenas estética: ela torna explícito onde termina o diagnóstico, onde começam as regras e em que momento a saída é validada.

8. Padrão de processo para todas as fontes

```
ENTRADA  
base bruta preservada  
  
↓  
  
PROCESSAMENTO  
regras documentadas e executadas  
  
↓  
  
VALIDAÇÃO  
qualidade e consistência  
  
↓  
  
SAÍDA  
base tratada ou corpus limpo
```

Esse padrão aplica ao projeto a lógica de processo estudada em Aquisição e Preparação de Dados: entradas são submetidas a recursos e procedimentos para produzir saídas. Na preparação, também são esperadas atividades como seleção de atributos, recodificação,

normalização quando necessária, limpeza, tratamento de dados faltantes e combinação de fontes.

9. Critérios gerais de qualidade

- Preservação: nenhum arquivo bruto será sobrescrito.
- Rastreabilidade: toda saída deverá indicar a origem e as regras que a produziram.
- Consistência: tipos, códigos e chaves deverão ser validados antes das integrações.
- Transparência: exclusões de registros e colunas serão contabilizadas e justificadas.
- Reprodutibilidade: o processo deverá ser executável novamente a partir das bases brutas.
- Prevenção de leakage: variáveis posteriores ao momento de classificação não alimentarão a Regressão Logística.
- Separação de responsabilidades: notebooks e scripts executam análises e transformações; relatórios consolidam os resultados acadêmicos.

10. Referências conceituais utilizadas

Este roteiro foi estruturado a partir dos materiais de apoio do Projeto Aplicado II, especialmente a Aula 2, que exige definição de bibliotecas, análise exploratória, tratamento da base, preparação/treinamento e definição dos métodos analíticos e de avaliação; e do material de Aquisição e Preparação de Dados, que trata mapeamento de processos, entradas e saídas, ETL/ELT e preparação de dados.

- MACKENZIE. Projeto Aplicado II - Aula 2: Etapas do Projeto.
- MACKENZIE. Aquisição de Dados - Aula 2: Mapeamento de processos, ETL e ELT.
- MACKENZIE. Aprendizado de Máquina I - materiais sobre preparação, classificação e avaliação.
- Dicionários oficiais das bases SINAN, CNES e IBGE utilizados no projeto.

Este documento é um roteiro técnico de limpeza. Os resultados efetivamente encontrados durante a execução deverão ser registrados no diário do projeto e consolidados nos relatórios correspondentes.