

# ROTEIRO COMPLEMENTAR - ENTREGA 2

## Projeto Aplicado II - Dengue

**Finalidade.** Este documento organiza, de forma resumida, as atividades da segunda entrega que não pertencem diretamente à limpeza das bases. Ele apresenta o que será feito, sem antecipar resultados de análises ainda não executadas.

**Escopo.** A limpeza de SINAN, CNES, IBGE e Informes está detalhada em documento próprio. Aqui permanecem: bibliotecas e repositório, análise exploratória, preparação para treinamento, fundamentação da Regressão Logística e método de avaliação.

| Exigência da Etapa 2                  | Como será atendida                                                                                |
|---------------------------------------|---------------------------------------------------------------------------------------------------|
| Bibliotecas Python e GitHub           | Definição das ferramentas e uso do repositório colaborativo.                                      |
| Análise exploratória                  | EDA das bases tratadas e da população elegível.                                                   |
| Tratamento / preparação e treinamento | Limpeza em documento próprio; depois, codificação, separação dos conjuntos e treinamento inicial. |
| Bases teóricas do método              | Fundamentação da Regressão Logística e justificativa de uso.                                      |
| Cálculo da acurácia                   | Definição das métricas e do protocolo de avaliação.                                               |

## 1. Bibliotecas Python e repositório GitHub

A entrega exige definir os pacotes Python e utilizar um repositório no GitHub para o trabalho colaborativo. No projeto, a escolha será mantida simples e diretamente ligada às tarefas previstas.

| Ferramenta     | Uso previsto                                                                                |
|----------------|---------------------------------------------------------------------------------------------|
| pandas / NumPy | Leitura, organização, transformação e cálculos sobre as bases tabulares.                    |
| Matplotlib     | Gráficos da análise exploratória e da avaliação do modelo.                                  |
| scikit-learn   | Pré-processamento, separação de conjuntos, Regressão Logística e métricas de classificação. |
| pdfplumber     | Extração de texto dos Informes Semanais, preservando a origem por documento e página.       |
| openpyxl       | Leitura do dicionário do IBGE em formato XLSX, quando necessário.                           |

**GitHub.** O repositório continuará sendo usado para versionar o mapeamento, notebooks, scripts, relatórios e a estrutura de dados. As bases brutas permanecem preservadas e os CSVs grandes continuam sob Git LFS.

**Resultado esperado desta atividade:** ambiente documentado e repositório organizado o suficiente para reproduzir a execução.

## 2. Análise Exploratória de Dados (EDA)

A EDA será feita depois da limpeza inicial. Seu objetivo será conhecer a população analisada, a qualidade das variáveis e o comportamento do alvo antes do treinamento. O relatório apresentará apenas resultados obtidos; o código ficará nos notebooks.

**A EDA deverá verificar, de forma objetiva:**

- quantidade de registros antes e depois dos critérios de elegibilidade;
- distribuição de **CLASSI\_FIN** e do alvo binário criado;
- percentual de valores ausentes ou ignorados nas variáveis candidatas;
- distribuições de idade, sexo, sintomas, comorbidades e demais variáveis mantidas;
- consistência das datas e dos códigos de município;
- distribuição dos indicadores municipais de CNES e IBGE após integração;
- existência de forte desbalanceamento entre as classes.

**Limite.** A EDA será descritiva. Frequências ou associações observadas não serão tratadas como causalidade nem como prova de risco individual.

### 3. Preparação para treinamento

A limpeza transforma os arquivos brutos em bases utilizáveis; a preparação para treinamento adapta essas bases ao método analítico. Essa etapa deverá ocorrer antes do ajuste da Regressão Logística.

| Atividade                      | Decisão prevista                                                                                                     |
|--------------------------------|----------------------------------------------------------------------------------------------------------------------|
| Definir população elegível     | Manter apenas registros com classificação compatível com o alvo definido.                                            |
| Evitar vazamento de informação | Excluir dos preditores variáveis que revelem gravidade, evolução ou informações posteriores ao momento de interesse. |
| Codificar categorias           | Transformar variáveis categóricas em representação adequada ao modelo, preservando o significado dos códigos.        |
| Tratar ausências               | Definir regras com base na EDA; não assumir automaticamente que ausente, ignorado e “não” são equivalentes.          |
| Separar conjuntos              | Reservar dados para treino e teste; se houver validação, ela será usada para decisões de desenvolvimento.            |
| Padronizar quando necessário   | Aplicar transformações apenas quando justificadas e aprendidas no conjunto de treino.                                |

**Resultado esperado desta atividade:** conjunto de dados preparado para o treinamento inicial, com regras registradas e sem utilizar o conjunto de teste para escolher o modelo.

### 4. Método analítico escolhido: Regressão Logística

A Regressão Logística será o método de classificação utilizado. O material da disciplina a apresenta como um classificador adequado a problemas binários, nos quais o resultado pertence a uma de duas classes. Essa característica é compatível com o alvo proposto para o projeto: dengue sem sinais de alarme versus dengue com sinais de alarme ou dengue grave.

**Justificativa da escolha.** O método tem relação direta com um alvo binário, é amplamente utilizado em classificação e permite analisar a direção e a intensidade dos coeficientes estimados, desde que sua interpretação respeite a codificação das variáveis e as limitações do estudo.

**Aplicação prevista.** O modelo receberá atributos selecionados do SINAN e, em uma versão enriquecida, indicadores municipais do CNES e do IBGE. A comparação SINAN isolado versus SINAN enriquecido permitirá verificar se o contexto municipal acrescenta informação ao classificador.

**Limitações esperadas.** Relações muito não lineares podem não ser bem representadas; variáveis fortemente correlacionadas podem dificultar a interpretação; classes desbalanceadas podem produzir acurácia aparentemente alta; e os coeficientes não serão interpretados como efeitos causais.

## 5. Método de avaliação

A avaliação será definida antes do treinamento para evitar escolher métricas apenas depois de observar os resultados. O conjunto de teste será reservado para a avaliação final.

| Métrica                | Uso no projeto                                                                                                  |
|------------------------|-----------------------------------------------------------------------------------------------------------------|
| Matriz de confusão     | Mostrar acertos e erros por classe, incluindo falsos positivos e falsos negativos.                              |
| Acurácia               | Medir a proporção total de classificações corretas.                                                             |
| Precisão               | Indicar, entre os casos previstos como positivos, quantos realmente pertencem à classe positiva.                |
| Recall / sensibilidade | Indicar quantos casos positivos foram identificados pelo modelo.                                                |
| F1-score               | Sintetizar precisão e recall em uma única medida, útil principalmente se houver desequilíbrio entre as classes. |

A disciplina exige descrever como a acurácia será calculada. No projeto, ela será entendida como a razão entre o número de classificações corretas e o total de casos avaliados. Entretanto, ela não será utilizada sozinha: precisão, recall, F1 e matriz de confusão também serão apresentados.

**Critério de honestidade.** Não será fixado antecipadamente um desempenho mínimo nem será prometida utilidade clínica. Resultados baixos ou limitações metodológicas também deverão ser reportados.

## 6. Tratamento analítico dos Informes Semanais

Os Informes constituem a parte textual do projeto. Depois da extração e limpeza dos PDFs, a análise deverá permanecer simples e rastreável. O objetivo será identificar temas, localidades, sorotipos e tendências mencionados nas seções de dengue, preservando informe e página de origem.

- frequência de termos e expressões relevantes;
- identificação de localidades e menções associadas à dengue;
- uso opcional de TF-IDF para destacar termos relativamente característicos entre documentos;
- revisão manual de uma amostra para reduzir interpretações fora de contexto.

**Limite.** A análise textual será complementar. Ela não será usada como variável de cada paciente nem será tratada como validação independente do modelo de classificação.

## 7. Ordem prevista para concluir a Entrega 2

| Ordem | Atividade                                       | Saída                                               |
|-------|-------------------------------------------------|-----------------------------------------------------|
| 1     | Concluir a limpeza das quatro fontes            | Notebooks e bases tratadas                          |
| 2     | Executar a EDA                                  | Notebook de EDA + resultados para o relatório       |
| 3     | Definir e aplicar a preparação para treinamento | Base analítica e regras documentadas                |
| 4     | Treinar a Regressão Logística                   | Implementação inicial no notebook/script            |
| 5     | Calcular as métricas definidas                  | Matriz de confusão, acurácia, precisão, recall e F1 |
| 6     | Consolidar a análise textual                    | Síntese dos Informes com rastreabilidade            |

| Ordem | Atividade                              | Saída                                       |
|-------|----------------------------------------|---------------------------------------------|
| 7     | Redigir o relatório técnico da Etapa 2 | Resultados, método, limitações e evidências |

Esse roteiro não substitui o relatório da Etapa 2. Ele apenas organiza o que deve ser executado e quais evidências deverão existir quando o relatório for escrito.

## Referências utilizadas

BORBA, Anderson Adaime de. *Projeto Aplicado II - Aula 2: Definição do produto analítico*. Mackenzie. Itens da Etapa 2: bibliotecas Python/GitHub, análise exploratória, tratamento/preparação e treinamento, bases teóricas do método e cálculo da acurácia.

SAMPAIO, Gustavo Scalabrini. *Aquisição e Preparação de Dados*. Mackenzie. Materiais sobre mapeamento, preparação, leitura e manipulação de dados.

OLIVEIRA, Rogério de. *Aprendizado de Máquina I*. Mackenzie. Aulas sobre Regressão Logística, separação treino/teste e métricas de classificação.

ANDRADE, Kassya Christina Rigolon de. *Introdução à Engenharia de Software*. Mackenzie. Materiais sobre requisitos e critérios de qualidade.