

## RELATÓRIO TÉCNICO – ETAPA 2

|                         |                                                   |
|-------------------------|---------------------------------------------------|
| COMPONENTE CURRICULAR:  | PROJETO APLICADO 2                                |
| NOME COMPLETO DO ALUNO: | GUILHERME CUNHA OLIVEIRA, GABRIEL LUCCA SIMIONATO |
| RA:                     | 10754621, 10751300                                |

Atenção: Toda atividade deverá ser feita com fonte Arial, tamanho 11, espaço de 1,5 entre as linhas e alinhamento justificado entre as margens.

### DEFINIÇÃO DO PRODUTO ANALÍTICO - ANÁLISE DA DENGUE

#### 1. Apresentação do relatório

Este relatório reúne, de forma objetiva, o que foi realizado na Etapa 2 do Projeto Aplicado II. O trabalho seguiu o Mapeamento de Processos do projeto e foi organizado para responder diretamente aos cinco itens exigidos no roteiro da disciplina, sem repetir em detalhes o que já está documentado nos notebooks e scripts.

| Exigência da Etapa 2                       | Onde aparece |
|--------------------------------------------|--------------|
| Bibliotecas Python e repositório GitHub    | Seção 2      |
| Definição das bases e análise exploratória | Seção 3      |
| Tratamento, preparação e treinamento       | Seção 4      |
| Bases teóricas dos métodos                 | Seção 5      |
| Cálculo da acurácia                        | Seção 6      |

#### 2. Bibliotecas e repositório GitHub

As ferramentas foram escolhidas de acordo com as tarefas realmente executadas no projeto. A ideia foi manter um conjunto simples de bibliotecas, suficiente para leitura, tratamento, visualização, modelagem e análise textual.

| Recurso                        | Uso no projeto                                                                |
|--------------------------------|-------------------------------------------------------------------------------|
| pandas e NumPy                 | Leitura, limpeza, transformação e integração das bases.                       |
| Matplotlib                     | Gráficos da análise exploratória e da avaliação.                              |
| scikit-learn                   | Pré-processamento, divisão dos dados, Regressão Logística, métricas e TF-IDF. |
| pdfplumber, openpyxl e pyarrow | Leitura de PDFs e XLSX e gravação dos arquivos intermediários.                |

O projeto está versionado no GitHub. As bases brutas são mantidas separadas das bases tratadas, e os arquivos CSV de maior volume usam Git LFS. Notebooks, scripts e documentação ficam em pastas próprias, para que o trabalho possa ser reproduzido sem alterar os arquivos originais.

Repositório: <https://github.com/GuimeOliver/PROJETO-APLICADO-II---BANCO-DE-DADOS>

### 3. Bases de dados e análise exploratória

Foram utilizadas quatro fontes: SINAN/Dengue 2025, CNES/Leitos 2025, IBGE/Censo 2022 e 17 Informes Semanais de Arboviroses de 2025. O SINAN é a base principal do modelo; CNES e IBGE acrescentam contexto municipal, e os Informes formam a trilha textual do projeto.

#### 3.1 População elegível e separação da avaliação

O SINAN possui 1.643.215 notificações. Após a retirada de 620 linhas totalmente duplicadas, foram considerados elegíveis os registros com CLASSI\_FIN 10, 11 e 12. O alvo foi definido como 0 para dengue sem sinais de alarme e 1 para dengue com sinais de alarme ou dengue grave. A base elegível ficou com 1.481.802 casos, dos quais 37.792 (2,55%) pertencem à classe positiva.

Antes da análise exploratória, 20% dos casos elegíveis (296.361) foram reservados para o conjunto de teste, de forma estratificada. A proporção 80/20 foi escolhida para manter volume suficiente no desenvolvimento do modelo e, ao mesmo tempo, preservar uma amostra independente para a avaliação final. A estratificação mantém no teste a mesma proporção da classe rara observada na base completa.

#### 3.2 Principais resultados da análise exploratória

Na base de desenvolvimento, a idade mediana foi de 35 anos e chegou a 39 entre os casos positivos. A proporção de alarme ou gravidade foi maior entre pessoas com 60 anos ou mais. O atraso entre os primeiros sintomas e a notificação teve mediana de 3 dias.




Figura 1 - Idade por classe do alvo e proporção de positivos por faixa etária.

O Sudeste concentrou a maior parte dos registros, mas a proporção de casos positivos foi maior no Centro-Oeste e no Nordeste. Esses valores descrevem a distribuição

observada e não devem ser interpretados como efeito causal da região sobre a gravidade.




Figura 2 - Casos elegíveis e proporção de alarme/gravidade por região de residência.

Entre os sintomas e comorbidades, vômito, leucopenia, náusea, hipertensão, diabetes e petéquias apareceram com maior frequência entre os casos positivos. A escolaridade teve preenchimento incompleto elevado, enquanto idade e intervalo entre sintomas e notificação apresentaram poucos valores ausentes.




Figura 3 - Diferença de frequência de sintomas e comorbidades entre casos positivos e negativos.

Na integração municipal, praticamente todos os códigos de residência encontraram correspondência no IBGE. O CNES mostrou diferenças importantes de capacidade instalada entre municípios, por isso os indicadores de leitos foram normalizados pela

população. Os indicadores de saneamento previstos no mapeamento ainda dependem da validação final do dicionário do IBGE e não foram usados no primeiro ajuste do modelo.

## **4. Tratamento, preparação e treinamento**

### **4.1 Limpeza e integração das bases tabulares**

No SINAN, as variáveis foram recodificadas com base no dicionário de dados, preservando a diferença entre valor ausente, ignorado e não se aplica. Datas e códigos municipais foram padronizados para permitir as integrações. Colunas de alarme, gravidade, hospitalização, evolução, óbito e outros campos posteriores ao momento da notificação ficaram fora dos preditores para evitar vazamento de informação.

O CNES foi agregado por município e competência, gerando medidas de leitos, UTI e número de estabelecimentos. O IBGE foi organizado em uma linha por município para fornecer população e características territoriais. As junções foram feitas pela chave municipal, preservando todos os casos do SINAN.

### **4.2 Estratégia para valores ausentes e variáveis categóricas**

O tratamento dos ausentes foi definido de acordo com o tipo de variável. Sintomas e comorbidades ausentes receberam imputação pela moda acompanhada de um indicador de imputação. Para variáveis numéricas contínuas, como idade, intervalo até a notificação e indicadores municipais, foi usada a mediana. Nas variáveis categóricas, categorias como ignorado e não se aplica foram mantidas, pois representam situações diferentes e podem carregar informação relevante.

As variáveis categóricas usadas no modelo foram transformadas por one-hot encoding. Essa escolha permite que categorias como sexo, raça, escolaridade, mês e região sejam utilizadas pela Regressão Logística sem criar uma ordem numérica artificial entre elas.

### **4.3 Padronização, divisão dos dados e primeiro treinamento**

As variáveis contínuas foram padronizadas por Z-score, por estarem em escalas muito diferentes. A padronização foi ajustada somente com os dados de treino e depois aplicada aos demais conjuntos, evitando que informações da validação ou do teste influenciassem o pré-processamento.

Depois da reserva de 20% para teste, o conjunto de desenvolvimento foi dividido novamente, de forma estratificada, em treino (948.352 casos) e validação (237.089 casos). A validação foi usada para acompanhar o desempenho durante o desenvolvimento; o teste permanece reservado para a avaliação final.

O método escolhido foi a Regressão Logística com ponderação de classes, porque apenas 2,55% dos registros pertencem à classe positiva. Foram avaliadas duas versões do mesmo modelo: uma usando apenas atributos do SINAN e outra acrescentando os indicadores disponíveis do CNES e do IBGE.

| Conjunto de atributos | Acurácia | Precisão | Recall | F1    | AUC-ROC |
|-----------------------|----------|----------|--------|-------|---------|
| SINAN isolado         | 70,0%    | 5,2%     | 62,1%  | 0,096 | 0,721   |
| SINAN + CNES + IBGE   | 70,8%    | 5,5%     | 64,4%  | 0,101 | 0,736   |

O ganho com o contexto municipal foi pequeno, porém consistente na validação. Como a classe positiva é rara, a precisão permaneceu baixa; por isso a acurácia não será analisada isoladamente.




Figura 4 - Matrizes de confusão e curvas ROC das duas versões do modelo na validação.

#### 4.4 Tratamento da base textual

Os 17 Informes Semanais foram tratados separadamente da base tabular. O texto foi extraído com preservação do número do informe e da página, e foram removidos elementos repetitivos, como cabeçalhos, rodapés e numeração de página. Em seguida, foi identificada a seção de dengue de cada documento e o texto foi normalizado para a análise.

Para representar os textos foi utilizado TF-IDF. A própria vetorização realiza a tokenização dos termos e atribui maior peso às palavras que são relevantes em um informe e menos comuns nos demais. Não foram usados embeddings ou lematização nesta etapa, porque o objetivo foi uma análise exploratória simples e rastreável, e não a construção de um modelo de linguagem.

Os resultados dos informes foram mantidos com referência ao documento e à página original. Isso é importante porque os valores apresentados nos boletins são acumulados ao longo das semanas epidemiológicas e não podem ser somados entre informes.




Figura 5 - Casos prováveis e óbitos confirmados acumulados, conforme os Informes Semanais.

## 5. Bases teóricas dos métodos analíticos

### 5.1 Estatística descritiva

A análise exploratória utilizou frequências, proporções, média, mediana, desvio padrão e quartis para entender a distribuição dos dados, o preenchimento das variáveis e as diferenças entre os grupos. Essas medidas ajudam a orientar o tratamento e a modelagem, mas não demonstram relação causal.

### 5.2 Regressão Logística

A Regressão Logística é um método de classificação binária que estima a probabilidade de um registro pertencer à classe positiva a partir de uma combinação das variáveis explicativas. Ela foi escolhida porque o objetivo do projeto também é binário: diferenciar dengue sem sinais de alarme de dengue com sinais de alarme ou grave. Além disso, seus coeficientes permitem observar a direção da associação entre os atributos e a probabilidade estimada, com a ressalva de que esses coeficientes não representam causalidade.

### 5.3 TF-IDF

O TF-IDF representa cada documento a partir da frequência dos termos, reduzindo o peso das palavras que aparecem em quase todos os textos e destacando termos mais característicos de cada informe. No projeto, ele foi usado como apoio à leitura comparativa dos boletins, mantendo a interpretação final vinculada ao texto e à página de origem.

## 6. Cálculo da acurácia e métricas de avaliação

A avaliação parte da matriz de confusão, que separa verdadeiros positivos, falsos positivos, falsos negativos e verdadeiros negativos. A acurácia corresponde à proporção total de classificações corretas. Como a classe positiva representa apenas 2,55% da base elegível, um modelo poderia ter acurácia alta apenas por prever a classe majoritária; por isso outras métricas são analisadas em conjunto.

| Métrica                | Como será interpretada                                                                     |
|------------------------|--------------------------------------------------------------------------------------------|
| Acurácia               | Proporção total de classificações corretas.                                                |
| Precisão               | Entre os casos previstos como alarme/grave, quantos realmente pertencem à classe positiva. |
| Recall (sensibilidade) | Entre os casos realmente positivos, quantos foram identificados pelo modelo.               |
| F1-score               | Síntese entre precisão e recall.                                                           |
| Matriz de confusão     | Quantidade de acertos e erros em cada classe.                                              |

Na validação da versão enriquecida, o modelo apresentou acurácia de 70,8%, precisão de 5,5%, recall de 64,4% e F1 de 0,101 no limiar de 0,5. Esses resultados são de desenvolvimento e não representam a avaliação final. O conjunto de teste reservado será usado uma única vez depois do fechamento das decisões de preparação e modelagem.

## 7. Síntese da etapa

A Etapa 2 deixou o projeto com as fontes organizadas, a análise exploratória realizada, as regras de tratamento registradas e um primeiro ajuste da Regressão Logística. O resultado ainda é preliminar e mostra limitações importantes, principalmente o forte desbalanceamento da classe positiva e a baixa precisão. O enriquecimento com CNES e IBGE trouxe melhora pequena na validação. Permanecem como pendências a validação dos indicadores de saneamento do IBGE e a avaliação final no conjunto de teste reservado.

## Referências

BORBA, Anderson Adaime de. Projeto Aplicado II - Aula 2: Definição do produto analítico. Universidade Presbiteriana Mackenzie (EaD).

SAMPAIO, Gustavo Scalabrini. Aquisição e Preparação de Dados. Universidade Presbiteriana Mackenzie (EaD).

OLIVEIRA, Rogério de. Aprendizado de Máquina I. Universidade Presbiteriana Mackenzie (EaD).

ANDRADE, Kassya Christina Rigolon de. Introdução à Engenharia de Software. Universidade Presbiteriana Mackenzie (EaD).

BRASIL. Ministério da Saúde. DATASUS. SINAN - Dengue: dicionário de dados da ficha de investigação. Brasília, 2025.

IBGE. Censo Demográfico 2022: agregados por municípios - notas metodológicas e dicionário de dados. Rio de Janeiro: IBGE, 2023.